Diseña tu primera herramienta con IA antes de construirla

7 pasos, un ejemplo completo de principio a fin, plantillas para copiar y las cuentas de cuánto cuesta.

Jonathan Rodríguez
Construir herramientas con IA, sin ser programador
linkedin.com/in/jonathanrod1986/

Antes de empezar

La mayoría de herramientas con IA que fracasan no fracasan por la IA. Fracasan porque nadie se sentó a diseñarlas: se abrió el chat, se escribió un prompt largo, funcionó tres veces y se declaró victoria. A la tarea número doscientas ya estaba inventando cosas.

Esta guía es la parte que casi nadie hace: **el diseño**. Son siete pasos que hago antes de escribir una sola línea de código o un solo prompt definitivo. Los aprendí construyendo herramientas en proyectos reales, muchas veces a las malas.

Para quién es

- Para quien ya usa la IA en el chat y quiere que haga una parte de su trabajo **siempre igual de bien**, no solo cuando está inspirada.
- No necesitas programar. Donde hay código, también está la versión en hoja de cálculo o en instrucciones, y cada línea va explicada.

Qué te llevas

- Un método de 7 pasos para pasar de «esto lo hago a mano» a una herramienta diseñada.
- Un ejemplo completo y ficticio que atraviesa toda la guía.
- Un prompt de clasificación, un esquema de salida, una fórmula, un filtro y una hoja de medición listos para adaptar.
- La cuenta de cuánto cuesta cada uso, con números.
- Una lista de verificación de una página.

El ejemplo que vamos a usar

Una tienda en línea de café (ficticia) recibe unas **300 reseñas al mes**. Hoy alguien del equipo las lee una por una, las pega en una hoja, les pone una etiqueta y al final del mes escribe un informe: de qué se queja la gente, qué le gusta y qué hay que atender ya. Le toma unas **10 horas al mes** y, como lo hace cansado, el informe depende del día que haya tenido.

Vamos a diseñar una herramienta que haga ese trabajo. Escogí este ejemplo porque se parece a mucho de lo que hacemos en marketing: leer mucho texto, ordenarlo y sacar conclusiones. Si tu tarea es otra (briefs, comentarios en redes, encuestas, propuestas, correos), cambia la palabra «reseña» por la tuya y el método sirve igual.

> **Ojo:** esta guía es de diseño. La herramienta puede terminar armada como un proyecto en tu asistente de IA con instrucciones fijas, como una hoja de cálculo que llama a la IA o como un programa pequeño. El diseño es el mismo en los tres casos, y es lo que más se salta la gente.

PASO 1

¿Vale la pena construirla?

Una vez armé una herramienta tan buena que nunca la usé. Funcionaba, era bonita, y se quedó guardada porque la tarea no se repetía lo suficiente. Desde entonces, antes de abrir cualquier cosa, califico la tarea con cinco preguntas.

Pregunta	0 puntos	1 punto	2 puntos
¿Se repite?	Una vez al año	Cada trimestre	Cada mes o más seguido
¿La puedo explicar en pasos?	«Depende», todo es criterio	La mayoría de pasos son claros	Se la explicaría a un practicante en una hoja
¿Sé cómo se ve bien hecha?	No tengo ejemplos	Tengo una idea	Tengo 5 a 10 ejemplos de «así queda bien»
¿Qué pasa si sale mal?	Llega al cliente sin que nadie lo vea	Lo nota alguien, tarde	Se ve enseguida y se arregla en un minuto
¿Cuánto me cuesta hoy?	Menos de una hora al mes	Unas horas al mes	Un día o más al mes, o la hace alguien caro

Cómo leer el puntaje: de 8 a 10, constrúyela. De 5 a 7, empieza con un buen prompt guardado y mide si de verdad lo usas. De 0 a 4, todavía no: sigue a mano y anota los pasos cada vez que la hagas, que eso ya es avanzar.

Aplicado al ejemplo

Pregunta	Puntos	Por qué
¿Se repite?	2	Cada mes
¿Pasos claros?	2	Leer, etiquetar, contar, resumir
¿Ejemplos de bien hecho?	1	Hay informes viejos, pero nadie ha etiquetado reseñas «oficiales»
¿Si sale mal?	1	Una queja grave mal clasificada se descubre tarde
¿Cuánto cuesta hoy?	2	10 horas al mes
Total	**8**	**Se construye.** Y ya sabemos dónde están los dos puntos flojos: faltan ejemplos y falta un filtro.

Fíjate en que el puntaje no solo dice sí o no: también te dice **qué te falta**. Los puntos que no sacaste son el plan de trabajo de los pasos 5 y 6.

PASO 2

Parte la tarea en piezas con entrada y salida

Este es el paso que más cambia las cosas. En vez de pensar la herramienta como «un prompt que lo hace todo», la partes en piezas. Cada pieza recibe algo, entrega algo y **deja su resultado guardado en un archivo**.

¿Por qué en archivos? Porque si una pieza falla, rehaces solo esa y no todo. Porque puedes revisar qué entró y qué salió de cada paso. Y porque el proceso deja de depender de que alguien lo corra en una conversación de chat que después nadie encuentra.

Para cada pieza decides también **quién manda**: la IA, una regla fija o una persona.

#	Pieza	Entra	Sale	Quién manda
1	Recoger	Exportación de la plataforma de reseñas	`resenas.csv` (id, fecha, estrellas, texto)	Regla
2	Limpiar	`resenas.csv`	`resenas_limpias.csv` sin nombres, correos ni teléfonos	Regla
3	Clasificar	Cada reseña limpia	`clasificadas.jsonl`: tema, sentimiento, frase clave	**IA**
4	Revisar	`clasificadas.jsonl`	Las que pasan y las que van a revisión humana	Regla (filtro)
5	Puntuar urgencia	Clasificadas que pasaron	Urgencia alta, media o baja	Regla (fórmula)
6	Contar	Todo lo anterior	`conteos.csv`: reseñas por tema, sentimiento y urgencia	Regla
7	Redactar	`conteos.csv` + frases clave	`informe.md`	**IA**
8	Aprobar	`informe.md`	Informe enviado	**Persona**

Mira la columna de la derecha: la IA solo manda en dos de ocho piezas, la 3 y la 7. Todo lo demás son reglas o personas. Eso no es desconfianza en la IA: es ponerla a hacer lo que hace bien, que es leer y redactar, y no lo que hace mal, que es contar y decidir cosas que no se negocian.

Una sola fuente de verdad

Los archivos tienen un orden: cada uno sale del anterior. El informe **se regenera** desde `conteos.csv`; nunca se edita a mano. Si alguien corrige una etiqueta, la corrige en `clasificadas.jsonl` y se vuelven a correr las piezas 4 a 7. Si editas el informe final a mano, la próxima vez que regeneres pierdes la corrección y ya no sabes qué número es el bueno.

Plantilla

PLANTILLA · MAPA DE PIEZAS

#	Pieza	Entra (archivo)	Sale (archivo)	Quién manda (IA / regla / persona)	¿Qué pasa si falla?
1					
2					
3					

Ojo con los datos personales: la pieza 2 no es un detalle. Si tus textos traen nombres, correos o teléfonos de clientes, quítalos antes de mandarlos a cualquier servicio de IA. En Colombia el manejo de datos personales lo regula la Ley 1581 de 2012; si trabajas con datos de clientes, revisa con quien corresponda en tu empresa qué puedes procesar y dónde.

PASO 3

Cierra la salida: lista fija y formato fijo

Si le pides a la IA «clasifica esta reseña», cada vez te va a inventar una categoría distinta: «envíos», «entrega», «demora en el envío», «logística». Cuatro nombres para lo mismo, y tus conteos ya no sirven.

La solución es **cerrar la salida** de dos maneras:

1. **Lista fija:** la IA solo puede escoger de una lista que tú defines. Lo que no encaja va a `no_mapeado`, y eso también es información: si `no_mapeado` crece, a tu lista le falta un tema.
2. **Formato fijo:** la IA responde siempre con la misma estructura, en JSON (un formato de texto ordenado por campos que cualquier programa o una hoja puede leer).

La lista del ejemplo

Campo	Valores permitidos
`tema`	producto, envio, cobro, atencion, empaque, no_mapeado
`sentimiento`	positivo, neutro, negativo
`frase_clave`	Una frase textual de la reseña, de máximo 15 palabras
`confianza`	alta, baja

El campo `confianza` es un truco útil: le pides a la IA que te diga cuándo duda. Las de confianza baja van a una segunda pasada (más abajo te explico cómo).

El prompt completo

```
Eres un clasificador de reseñas de una tienda en línea de café.
Lee la reseña y responde SOLO con un objeto JSON, sin texto antes ni después.

Campos:
- "tema": uno de [producto, envio, cobro, atencion, empaque, no_mapeado]
- "sentimiento": uno de [positivo, neutro, negativo]
- "frase_clave": copia textual de la frase que justifica el tema
  (máximo 15 palabras; no la reescribas)
- "confianza": "alta" si la reseña habla claramente de un tema,
  "baja" si mezcla temas o es ambigua

Si la reseña habla de varios temas, escoge el que más pesa en la queja
o el elogio y marca confianza "baja".
Si no habla de ninguno de la lista, usa "no_mapeado".
No inventes temas nuevos.

Reseña (id {id}, {estrellas} estrellas):
"""{texto}"""
```

Lo que debe devolver

```
{"tema": "envio", "sentimiento": "negativo",
 "frase_clave": "llevo diez días esperando y nadie me responde",
 "confianza": "baja"}
```

En este caso la confianza es baja con razón: la reseña habla del envío y también de la atención. Una herramienta que sabe cuándo duda vale más que una que siempre está segura.

> **Detalle técnico que ahorra dolores de cabeza:** si usas la IA por API (conectada a un programa), dale un límite de respuesta holgado cuando pides JSON. Si el límite es muy justo, la respuesta se corta a la mitad y el JSON queda roto. Si aun así llega roto, el programa reintenta una vez y, si vuelve a fallar, manda esa reseña a revisión. Nunca «adivina» el pedazo que faltó.

PASO 4

La IA propone, las reglas deciden

Este es el error más común: meterle al prompt las reglas que no se negocian. «Si es una queja de cobro con una estrella, márcala urgente». Funciona en las pruebas, pero para la IA eso es una sugerencia, y a la reseña doscientas la va a interpretar a su manera.

Lo que no se negocia va **por fuera**, en una regla fija. En el ejemplo, la urgencia no la decide la IA: la calcula una fórmula con lo que la IA ya clasificó.

La regla de urgencia

- +2 puntos si el sentimiento es negativo.
- +2 puntos si el tema es `envio` o `cobro` (los que más le duelen al cliente y a la tienda).
- +1 punto si la reseña tiene 1 o 2 estrellas.
- **Alta** con 4 o más puntos, **media** con 2 o 3, **baja** con 0 o 1.

En hoja de cálculo (sin programar)

Con el sentimiento en la columna C, el tema en la D y las estrellas en la E:

```
F2 (puntos):   =(C2="negativo")*2 + (O(D2="envio"; D2="cobro"))*2 + (E2<=2)
G2 (urgencia): =SI(F2>=4; "alta"; SI(F2>=2; "media"; "baja"))
```

(En hojas configuradas en inglés, `O` es `OR`, `SI` es `IF` y el separador es coma.)

En Python

```
def urgencia(r):
    puntos = 0
    if r["sentimiento"] == "negativo":
        puntos += 2
    if r["tema"] in ("envio", "cobro"):
        puntos += 2
    if r["estrellas"] <= 2:
        puntos += 1
    if puntos >= 4:
        return "alta"
    return "media" if puntos >= 2 else "baja"
```

Fíjate en algo: la IA **nunca ve** esta regla. No sabe que existe el umbral de 4 puntos, así que no tiene cómo interpretarlo, olvidarlo ni «ser creativa» con él. Si mañana decides que `empaque` también es urgente, cambias una línea y la regla se aplica igual a las 300 reseñas, sin reescribir el prompt ni volver a pagar la clasificación.

La misma lógica para el informe

La pieza 7 (redactar) también la usa la IA, pero sobre **números que ya calculó una regla**. La IA no cuenta: recibe `conteos.csv` y lo convierte en texto. Y después, cada frase del informe que tenga una cifra se compara contra `conteos.csv`. Si el informe dice «el 40 % de las quejas son de envío» y el archivo dice 31 %, el informe no sale.

PLANTILLA · ¿IA O REGLA?

Para cada decisión de tu herramienta, pregúntate:

- ¿Hay una respuesta correcta que se pueda escribir como regla? **Regla.**
- ¿Es un número, un conteo, un umbral o un veto? **Regla.**
- ¿Requiere leer, entender un texto, resumir o redactar? **IA.**
- ¿Tiene consecuencias con un cliente o con plata? **Regla, o persona.**

PASO 5

Arma tu set dorado y mide

¿Cómo sabes si la herramienta clasifica bien? «Se ve bien» no es una respuesta. Necesitas un **set dorado**: un grupo de ejemplos que tú etiquetaste a mano con cuidado y contra el que comparas lo que hizo la herramienta.

Cómo armarlo

1. Escoge **50 reseñas** al azar, no las más fáciles ni las más raras.
2. Etiquétalas tú, a mano, con la misma lista del paso 3. Si pueden, que las etiqueten dos personas por separado y discutan donde no coincidan: ahí aparecen los temas mal definidos.
3. Guárdalas en un archivo aparte. **Ese archivo no se toca** para ajustar el prompt; es tu examen.
4. Corre la herramienta sobre esas 50 y compara.

Las tres cifras que importan

Supón que miramos solo el tema `envio`:

- En el set dorado hay **14** reseñas de envío.
- La herramienta marcó **12** como envío.
- De esas 12, **10** eran de envío de verdad.

Medida	Pregunta que responde	Cuenta	Resultado
Precisión	De lo que marcó como envío, ¿cuánto era envío?	10 ÷ 12	83 %
Cobertura	De todo lo que era envío, ¿cuánto encontró?	10 ÷ 14	71 %
F1	Las dos juntas en una sola cifra	2 × 0,83 × 0,71 ÷ (0,83 + 0,71)	0,77

Lectura: cuando dice «envío» casi siempre acierta, pero **se le escapan** casi 3 de cada 10 quejas de envío. Para una tienda donde el envío es el dolor principal, eso es grave: hay que revisar dónde las está mandando (seguramente a `atencion`) y ajustar la definición de los temas.

Las dos pasadas

1. **Primera pasada:** la herramienta clasifica todo.
2. **Segunda pasada:** solo las de `confianza: baja` se vuelven a clasificar, con un prompt que muestra un par de ejemplos resueltos de casos dudosos. Si siguen en duda, van a revisión humana.

Las segundas pasadas suelen ser pocas, así que salen baratas, y es donde más se gana en calidad.

Regla de oro: decide **antes** de medir qué cifra te parece suficiente para usar las etiquetas, y escríbela. Si la decides después de ver el resultado, siempre te va a parecer suficiente. El umbral depende de lo que esté en juego: no es lo mismo un informe interno que una alerta que dispara una llamada a un cliente.

PLANTILLA · HOJA DEL SET DORADO

id	texto (recortado)	tema a mano	tema herramienta	¿coincide?	sentimiento a mano	sentimiento herramienta	¿coincide?	nota

Abajo: precisión, cobertura y F1 por tema, y el umbral que decidiste antes de medir.

PASO 6

Pon filtros que bloqueen, no que avisen

Un filtro que avisa termina ignorado: a la tercera semana nadie lee las advertencias. Un filtro que **bloquea** no deja salir la respuesta: la manda a revisión y punto.

Los filtros del ejemplo

Filtro	Qué revisa	Si falla
Formato	Que la respuesta sea JSON válido con los cuatro campos	Reintenta una vez; si vuelve a fallar, va a revisión
Lista cerrada	Que `tema` y `sentimiento` sean valores de la lista	Revisión
Frase textual	Que `frase_clave` aparezca de verdad dentro de la reseña	Revisión (la IA la reescribió o la inventó)
Coherencia	Que no haya «positivo» con 1 estrella ni «negativo» con 5	Revisión
Cifras del informe	Que cada número del informe coincida con `conteos.csv`	El informe no sale

En Python

```
TEMAS = {"producto", "envio", "cobro", "atencion", "empaque", "no_mapeado"}
SENTIMIENTOS = {"positivo", "neutro", "negativo"}

def revisar(r, texto, estrellas):
    errores = []
    if r.get("tema") not in TEMAS:
        errores.append("tema fuera de la lista")
    if r.get("sentimiento") not in SENTIMIENTOS:
        errores.append("sentimiento fuera de la lista")
    if r.get("frase_clave", "").lower() not in texto.lower():
        errores.append("la frase clave no está en la reseña")
    if r.get("sentimiento") == "positivo" and estrellas == 1:
        errores.append("positivo con 1 estrella")
    if r.get("sentimiento") == "negativo" and estrellas == 5:
        errores.append("negativo con 5 estrellas")
    return errores   # si la lista no está vacía, la reseña NO pasa
```

El filtro de la frase textual es mi favorito: es una forma muy barata de pillar a la IA cuando inventa. Si te dice que la frase clave es «el café llegó frío» y esa frase no está en la reseña, algo anda mal, aunque el tema esté bien.

Antes de la primera corrida: la prueba mínima

Antes de mandar 300 reseñas, manda **una**. Revisa que el modelo que pediste responda, que el JSON llegue completo y que los filtros lo dejen pasar. Parece obvio, pero un modelo que aparece en la lista del proveedor puede no estar disponible para tu cuenta, o responder distinto de lo que esperabas. Es mejor enterarse con una reseña que con trescientas.

PASO 7

Calcula cuánto cuesta cada uso

Si no sabes cuánto cuesta cada uso, no sabes si la herramienta vale la pena, y tampoco tienes cómo ponerle un tope. Los servicios de IA cobran por **tokens**: pedacitos de texto. En español, como referencia aproximada, un token son unos 4 caracteres.

La cuenta del ejemplo

Concepto	Supuesto	Tokens
Prompt fijo (instrucciones + lista)	~2.800 caracteres	~700
Reseña promedio	~480 caracteres	~120
Entrada por reseña		**~820**
Respuesta JSON	~320 caracteres	~80
300 reseñas: entrada	300 × 820	246.000
300 reseñas: salida	300 × 80	24.000

Con un **precio de ejemplo** de US$3 por millón de tokens de entrada y US$15 por millón de salida (los precios cambian y dependen del modelo: revisa los de tu proveedor el día que hagas la cuenta):

Parte	Cuenta	Costo
Clasificar 300	0,246 M × 3 + 0,024 M × 15	US$1,10
Segunda pasada (~15 %)	proporcional, con prompt más largo	~US$0,25
Redactar el informe	una llamada	~US$0,05
Total al mes		**~US$1,40**

Contra 10 horas de trabajo al mes, la cuenta se hace sola. Pero el punto no es que sea barato; es que **lo sabes**, y con eso puedes poner topes.

Tres reglas de costo

1. **Tope por corrida y por mes.** Si una corrida va a costar más que el tope (porque llegaron 3.000 reseñas en vez de 300, o porque algo se quedó en un ciclo), se detiene sola y avisa.
2. **Lo que ya pagaste se guarda.** Cada clasificación queda en `clasificadas.jsonl` con el id de la reseña. Si cambias la regla de urgencia o el formato del informe, **no vuelves a clasificar**: corres las piezas 5 a 7 sobre lo guardado. Solo se paga lo nuevo.
3. **Si la publicas, ciérrala.** Una herramienta con un formulario abierto en internet es un grifo abierto a tu presupuesto. Si otras personas la van a usar, que sea con acceso controlado.

Errores que ya vi (para que no los repitas)

Error	Cómo se ve	Qué hacer
Todo en un prompt	Funciona en la demo y se desvía con el volumen	Partir en piezas (paso 2) y sacar las reglas (paso 4)
Lista abierta	«Envíos», «entrega», «logística»: conteos que no suman	Lista cerrada + `no_mapeado` (paso 3)
Medir «a ojo»	«Se ve bien»	Set dorado con umbral decidido antes (paso 5)
Ajustar el prompt mirando el examen	El set dorado da 100 % y en la vida real no	El set dorado no se toca para ajustar; usa otros ejemplos para eso
Filtro que avisa	Advertencias que nadie lee	Filtro que bloquea y manda a revisión (paso 6)
Editar el resultado a mano	La corrección se pierde al regenerar	Corregir en la fuente y regenerar (paso 2)
Volver a pagar todo	Cada cambio de formato cuesta la corrida completa	Guardar lo pagado y reutilizarlo (paso 7)
Mandar datos personales	Nombres y correos en el servicio de IA	Pieza de limpieza antes de todo (paso 2)

Lista de verificación

Antes de construir, deberías poder marcar todo esto:

- ☐ Califiqué la tarea con las 5 preguntas y sacó 8 o más (o sé qué me falta).
- ☐ Partí la tarea en piezas, cada una con un archivo de entrada y uno de salida.
- ☐ Para cada pieza decidí quién manda: IA, regla o persona.
- ☐ La IA solo manda donde hay que leer, entender o redactar.
- ☐ Definí la lista cerrada de valores, con `no_mapeado`.
- ☐ Tengo el prompt con formato fijo de respuesta y el campo de confianza.

- ☐ Las reglas que no se negocian están por fuera del prompt.
- ☐ El texto final se redacta sobre números ya calculados, y las cifras se verifican.
- ☐ Armé un set dorado de unas 50 piezas, etiquetado a mano, que no se toca.
- ☐ Escribí el umbral de calidad **antes** de medir.
- ☐ Los filtros bloquean; no solo avisan.
- ☐ Hice la prueba mínima con un solo caso.

- ☐ Sé cuánto cuesta cada uso y puse un tope por corrida y por mes.
- ☐ Lo que ya pagué queda guardado y se reutiliza.
- ☐ Quité los datos personales antes de mandar nada a la IA.

De dónde sale esto

Todo lo de esta guía lo he aplicado en herramientas reales de estrategia y marketing. El ejemplo de la tienda de café es **ficticio** y los números de costo son un ejemplo con precios supuestos: haz tu cuenta con tus volúmenes y los precios del día.

No soy programador; vengo de la estrategia. Esto lo he aprendido construyendo, así que habrá cosas que alguien de ingeniería haría distinto, y me sirve que me lo digan.

En la próxima guía: cómo hacer que la IA no invente, a fondo: listas cerradas para casos difíciles, cómo se arma y se mantiene un set dorado, y filtros más finos.

Si esta guía te sirvió, guárdala y pásasela a alguien que esté a punto de armar algo con IA.